DRAFT LAPORAN TAHAP 1 (Eksplorasi & Preprocessing)

Proyek Akhir Tahap 1 - Eksplorasi Data dan Praproses Dataset Laptop Price

1. Identitas dan Paket Dataset

   Kelas : Informatika 5A

   Nama Anggota :

   Faiz Muzaki Irsyad (2488010047)

   Ashfahani Hasyim (2488010070)

   Alvin perdiansyah dwi putra (2488010019)

   Kelompok : 4

   Nama Paket Dataset : Laptop Price (Paket 5A-4)

   Metode Kelompok : Klastering (K-Means)

   Nama Berkas yang Dipakai : laptop_price.csv (diambil dari Kaggle)

2. Deskripsi Data

   Dataset ini diambil dari platform Kaggle (Laptop Price). Data ini berisi daftar harga dan spesifikasi dari berbagai varian laptop yang dijual di pasar Eropa. Total ada 1.303 baris dan 13 kolom.

   Unit analisisnya: Satu baris data mewakili satu varian laptop yang dijual, lengkap dengan spesifikasi perangkat keras dan harganya.

3. Kamus Data

Nama Kolom	Arti dalam Bahasa Indonesia	Satuan	Tipe Data	Peran
laptop_ID	Nomor unik identitas laptop	-	Numerik	Identifier (Dibuang)
Company	Merek pembuat laptop	-	Kategori	Fitur
Product	Nama model laptop	-	Kategori	Fitur
TypeName	Jenis laptop (Notebook, Gaming, dll)	-	Kategori	Fitur
Inches	Ukuran layar laptop	Inci	Numerik	Fitur
ScreenResolution	Resolusi layar	-	Teks	Dibuang (dipecah)

Cpu	Prosesor laptop	-	Teks	Dibuang (dipecah)
Ram	Memori RAM	GB	Teks	Dibuang (dipecah)
Memory	Media penyimpanan	-	Teks	Dibuang (dipecah)
GPU	Kartu grafis	-	Kategori	Fitur
OpSys	Sistem operasi	-	Kategori	Fitur
Weight	Berat laptop	kg	Teks	Dibuang (dipecah)
Price_euros	Harga laptop	Euro	Numerik	Target/Variabel

4. Temuan Pemeriksaan Mutu Data
    - Setelah kami cek pakai kode, ini temuan kami:
    - Nilai Hilang (Missing Values): Aman, 0 (nol) nilai hilang di semua kolom.
    - Duplikat: Tidak ada baris data yang terduplikat.
    - Data Hilang Tersamar / Nilai Mustahil: Tidak ada data aneh yang tersamar, tapi kami menemukan banyak data numerik yang masih berupa teks bersatuan. Contoh: kolom Ram isinya teks "8GB", dan Weight isinya "1.37kg". Ini harus dibersihkan karena mesin nggak bisa hitung jarak kalau datanya masih ada hurufnya.
    - Kolom Konstan & Identifier: Ditemukan kolom laptop_ID yang nilainya unik di setiap baris. Ini bahaya kalau masuk ke model, jadi kami buang.

5. Analisis Target dan Hubungan (K-Means)

    Karena metode kami adalah K-Means (Klastering), kami tidak punya target (variabel Y). Tugas kami adalah menyiapkan ruang fitur. Dasar segmentasi yang kami pakai adalah spesifikasi hardware: RAM, Ukuran Layar (Inches), Berat, dan Storage.

    Kami mengecek sebaran harga (Price_euros) dan ternyata datanya menceng ke kanan (right-skewed). Banyak laptop murah, tapi ada beberapa yang harganya ekstrem mahal. Supaya nggak merusak model, kami melakukan Transformasi Logaritma (LogPrice).

    Kami juga memastikan bahwa Price_euros tidak kami masukkan ke dalam fitur K-Means, agar klaster yang terbentuk murni berdasarkan kemiripan spesifikasi, bukan karena harganya.

6. Tabel Keputusan Praproses

Kolom / Baris	Temuan	Keputusan	Alasan	Baris Terpengaruh
laptop_ID	Nilai unik di tiap baris	Dibuang	Identifier tidak boleh jadi fitur model	0 baris

Ram	Teks "8GB", "16GB"	Dibersihkan jadi Ram_GB (Angka)	K-Means hanya bisa hitung angka	1.303 baris
Weight	Teks "1.37kg"	Dibersihkan jadi Weight_kg (Angka)	K-Means hanya bisa hitung angka	1.303 baris
Memory	Gabungan SSD/HDD ("128GB SSD + 1TB HDD")	Dipecah jadi Storage_GB, Has_SSD, Has_HDD	Biar mesin tahu kapasitas asli dan jenis medianya	1.303 baris
ScreenResolution	Gabungan resolusi & layar sentuh	Dipecah jadi Touchscreen, IPS, Res_W, Res_H	Mengambil informasi yang berguna saja	1.303 baris
Price_euros	Nilai besar & menceng ke kanan	Ditransformasi jadi LogPrice	Biar distribusinya lebih normal	1.303 baris

7. Rencana Tahap 2 dan Keterbatasan
    - Rencana Tahap 2: Di tahap selanjutnya, kami akan melakukan Penskalaan (StandardScaler) pada fitur yang sudah bersih ini. Ini wajib karena K-Means mengukur jarak, dan skala RAM (4-32) beda jauh sama skala Harga (ratusan-ribuan). Setelah di-scaling, kami akan mencari jumlah klaster (k) paling pas pakai Elbow Method dan Silhouette Score, lalu memberi nama tiap segmen klaster.
    - Keterbatasan: Data ini tidak punya informasi tentang kondisi fisik laptop (misal bekas atau baru), tahun rilis, dan tidak ada riwayat penjualan. Jadi hasil klaster ini murni cuma berdasarkan spesifikasi teknis di atas kertas aja.